

Projektarbete

IOOPM 2014

Tobias Wrigstad
tobias.wrigstad@it.uu.se



Parametrar

- Grupper om 6 personer, uppdelade i 3 par som roterar "hela tiden"
- Redovisning med två grupper åt gången för att jämföra lösningar och problem

Både kod och "process"

- Två möjliga redovisningsdatum

Slutet december, mitten januari — välj själva (anmälan öppnar senare)

- Varje grupp har en coach — listan anslås på portalen

2–3 handledningsmöten som ni bokar

- Handlednings- och redovisningstillfällen som vanligt (dock annat schema)

På inget sätt projektspecifika



Syftet med projektet

- Förståelse för automatisk minneshantering
- Förståelse för varför processer, etc. verktyg behövs
- Pröva på mjukvaruutveckling i projektarbetsform, t.ex.

Komplicerade beroenden, svårt att modularisera, svårt att kommunicera

Använda Trello för att spåra och lägga upp arbetet

Förstå och navigera en 21-sidors specifikation

- Få en baseline för personliga mått för framtida tidsestimat



Bedömningskriterier

- 1. den inlämnade kodens kvalitet och kompletthet,
- 2. inlämnad dokumentation,
- 3. kvalitet på testfall, samt
- 4. aktivt deltagande i utvecklingsprocessen.

- Vad händer om man inte är klar?

Godkänt ändå: (se detaljer i specen)

Rest: ett nytt försök med ny överenskommen deadline

Underkänt: om för långt ifrån klar eller det saknas en plan för vad som skall fixas



Övriga mål som redovisas

- Y66 – Kodgranskning
- Y63 – Testdriven utveckling
- Y64 – Tillämpa Scrum eller Kanban
- Y65 – Kodstandard
- X67 – Parprogrammering

- (Se specen och AU-portalen för mer information)



Inlämning (Y68)

- Övergripande designdokument
- Koddokumentation på gränssnittsnivå (t.ex. mha. doxygen)
- Själva koden
- Enhetstester
- Individuella reflektioner

Parprogrammering

Självreflektion

- Gemensam reflektion



Obligatoriska verktyg

- valgrind

Löpande under utvecklingen – det kommer att vara GULD värt

- cunit

För era enhetstester

- gcov

För att se hur bra era tester täcker programmet

- gprof

För att göra prestandamätningar i samband med integrationstesten



Projektarbetets domän



Minneshantering

- Manuellt

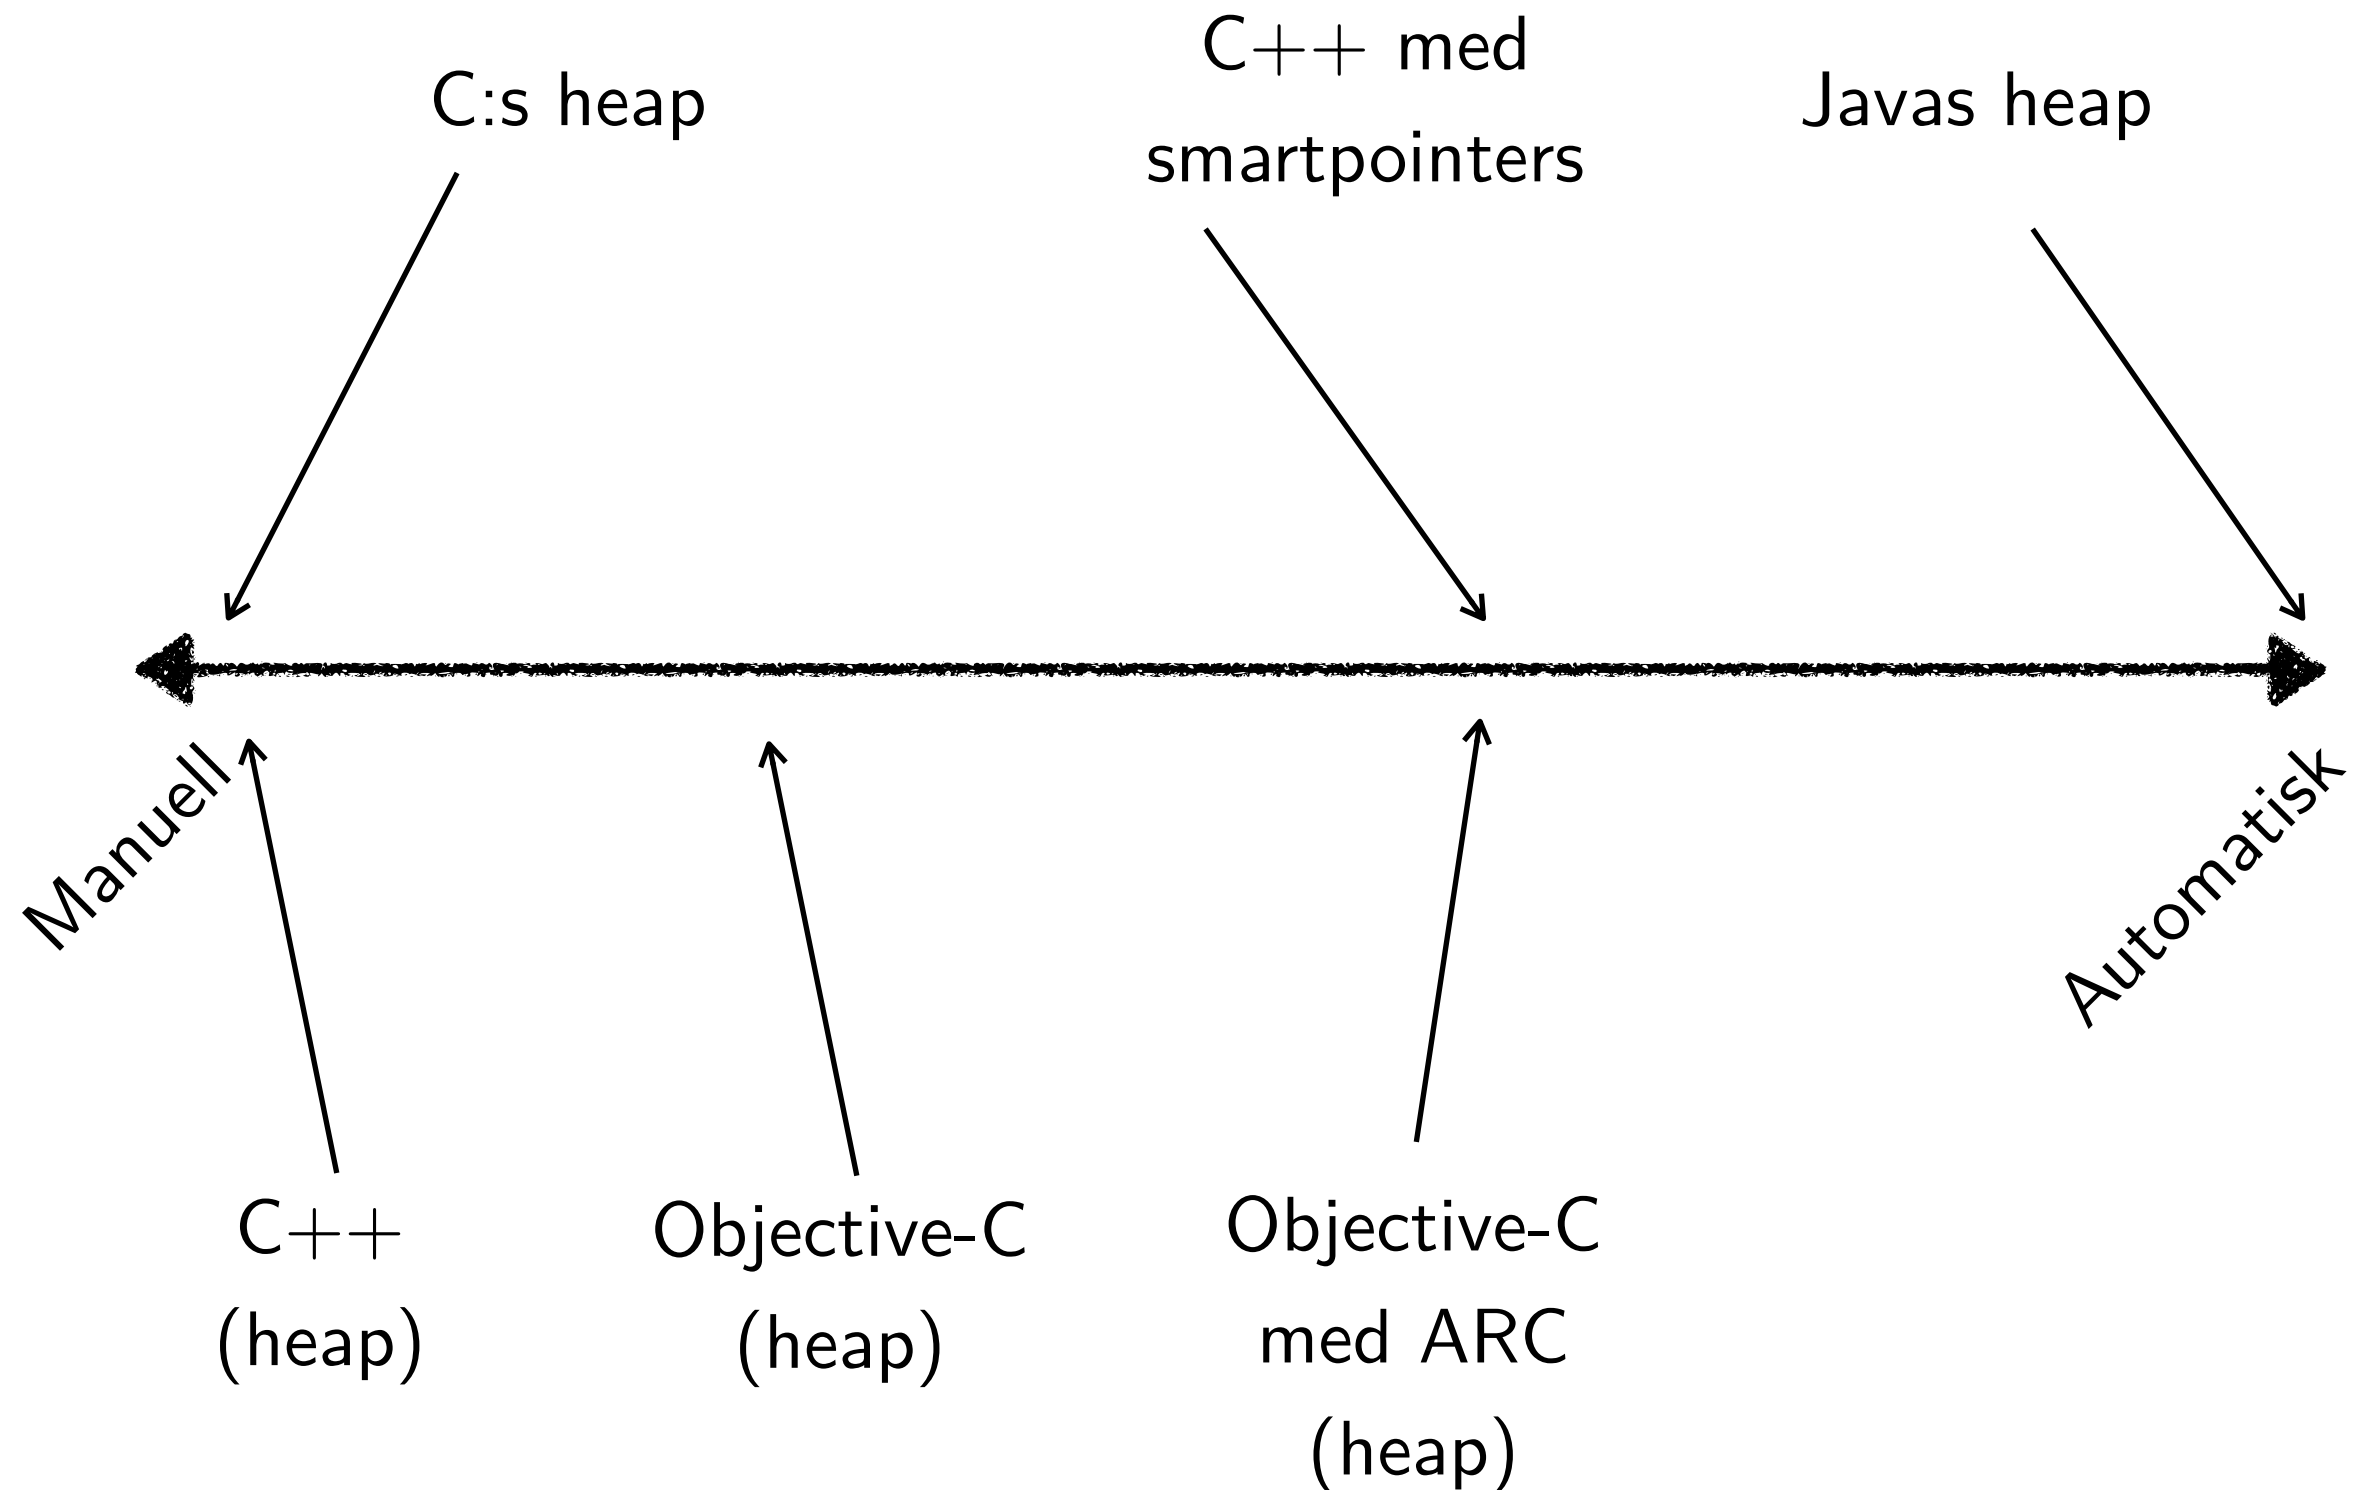
Programmeraren måste explicit begära minne av rätt storlek och återlämna

- Automatiskt

Minne av rätt storlek begärs automatiskt och återlämnas automatiskt



En glidande skala med några exempel



Olika tekniker för minneshantering

- Stacken

- Malloc & free (C, C++)

- Referensräkning (reference counting)

Explicita retain/release-anrop (t.ex. traditionell Objective-C)

Automatiska anrop till retain/release (t.ex. Python, Swift)

- Tracing GC

Mark-sweep (Ruby, Python)

Mark-compact

- Hybrider: generational GC, G1, etc. (Java)



(En naiv) Malloc & free

- Ha en lista A över allokerade block och en lista F över lediga block

Initialt, A tom, $F = [\text{Heapen}]$

- $\text{Malloc}(N) = p$

1. Hitta block B i F med minst N bytes, låt p vara dess startadress
2. Dra av N bytes från B och ändra dess startadress till $p + N$
3. lägg till ett N-bytes block i A med p som startadress

Hur F är sorterad påverkar hela systemet (fragmentering, hastighet)

- $\text{Free}(p)$

1. Leta upp ett block med startadress p i A, flytta det till F
2. Om angränsande block finns i F — slå samman blocken



Referensräkning

- Varje objekt O har en räknare R_O för antalet inkommande referenser

När objektet O skapas är $R_O = 0$

Varje gång en referens till O sparas i en variabel, R_O++

Varje gång en referens till O förstörs, R_O--

När R_O når 0, ta bort objektet (t.ex. med free)

- Manuell referensräkning: retain(ptr) och release(ptr)
- Inget stöd för cykler!

Python (bl.a.) använder tracing GC som komplement till referensräkning



Tracing GC

- Allokera efter någon princip så länge det finns ledigt minne
- När allokering misslyckas på grund av minnesbrist, trigga skräpsamling
- Skräpsamling i två faser: mark och sweep

Betrakta minnet som en graf; noder = objekt, bågar = referenser

Mark: utifrån alla objekt **som pekas ut från stacken**, besök alla objekt som går att nå från dessa och markera dem som "levande"

Sweep: ta bort alla objekt som inte är levande

- Efter skräpsamling, försök allokera på nytt och hoppas på att ledigt minne nu finns

90–95% av alla objekt brukar tas bort vid en GC-körning i OO-språk som Java



Mark-Sweep

- Allokering av minne sker analogt med malloc & free

Lista A över allokerade block, lista F över lediga ("free") block

- När malloc misslyckas, trigga GC
- När vi traverserar de levande objekten, flytta över de block i A som de ligger på till en ny lista N
- Efter alla traverseringar kan vi flytta allt som är kvar i A till F
- N blir nya A



Mark-Compact

- Effektiv allokering med "bump pointer"

Ha en startadress S till heapen och en slutadress E

Allokering av ett objekt O placerar O vid S och flyttar fram S med $\text{sizeof}(O)$ bytes

När S når E är minnet fullt och skräpsamling måste ske

- Skräpsamling

I samband med traversering — flytta alla levande objekt så att de ligger i ett sammanhängande minne

Problem 1: hur vet vi vad vi kan skriva över?

Problem 2: vi måste uppdatera alla pekare till flyttade objekt



Generationstekniker

- Dela in heapen i olika regioner för objekt av olika ålder

Ålder bestäms av hur många GC-pass objektet överlevt

- Hantera minnet olika i olika regioner (t.ex. ung, medelålders, gammal)

- Bakomliggande tankar

Objekt dör unga (cf. 90–95% vid nästa GC)

Gamla objekt tenderar att leva länge

Objekt som överlever en skräpsamling flyttas till nästa region

Varje region skräpsamlas för sig

Minskar upprepat arbete på långlivade objekt



Några observationer och ”jämförelser”

- Malloc & free

Komplicerat att programmera med (vem skall free:a?) och därför felbenäget

- Referensräkning

Betydligt enklare programmering men fungerar inte med cykler (också knepigt om objekt delas mellan trådar)

- Tracing GC

Måste stanna världen för att samla skräp — leder till pauser i programmet

- Mark–Compact

Behöver i regel mer minne men ger bättre lokalitet och snabbare allokering



Saker som jag inte har pratat om

- Incrementell och parallel GC

Hur får vi GC att fungera i ett parallelexekverande program utan att stoppa alla trådar?

(All Tracing GC har varit "stop the world")

- Lokalitet

Det är bättre om objekt som används tillsammans ligger nära varandra i minnet (varför?) — hur kan man uppnå det? (Mark-compact bättre här)

- Starka och svaga pekare

- ...



Projektarbete



Projektarbetet

- "Implementera en automatisk minneshanterare av typen Mark–Compact som skall fungera för godtyckliga C-program"

- Förenklingar

Vi stöder inte pekare in i objekt (t.ex. istring)

Vi implementerar mha. two-space (enkelt men slösaktigt)

Vi använder allokering med metadata för att identifiera pekare

- En massa rolig C-programmering

Bitmanipulering, bitvektorer, funktionspekare

- Prestandamätningar

Balansera overhead för skräpsamling med prestanda från bättre lokalitet



Gränssnittet mot skräpsamlaren

```
typedef struct heap_t heap_s;
```

```
typedef void *(*trace_f)(heap_s *h, void *obj);
```

```
typedef void *(*s_trace_f)(heap_s *h, trace_f f, void *obj);
```

```
heap_s *h_init(size_t bytes);
```

```
void h_delete(heap_s *h);
```

```
void h_delete_dbg(heap_s *h, void *dbg_value);
```

```
void *h_alloc_struct(heap_s *h, char *layout);
```

```
void *h_alloc_union(heap_s *h, size_t bytes, s_trace_f f);
```

```
void *h_alloc_raw(heap_s *h, size_t bytes);
```

```
size_t h_gc(heap_s *h);
```

```
size_t h_avail(heap_s *h);
```



Gränssnittet mot skräpsamlaren

```
#include <stdio.h>
#include "gc.h"

int main(int argc, char *argv[])
{
    heap_s *h = h_init(1024);

    tree_node *t = h_alloc_struct(h, "d**");
    list_node *l = h_alloc_struct(h, "d*");
    printf("Available memory: %lu\n", h_avail(h));

    h_gc(h);
    printf("Available memory: %lu\n", h_avail(h));

    h_delete_dbg(h, (void *)0xDEADBEEF);
    return 0;
}
```



Ett inbyggt problem

- För att hitta rötterna till traverseringen måste vi scanna stacken efter vad som ser ut som pekare
- Risk att vi identifierar värden som pekare som inte är pekare

För att detta skall ske måste vi hitta ett värde `sizeof(void*)` som är samma som en adress som returnerats av vår allokerare.

- Om detta sker — BOOM!!!

Vad är sannolikheten? På 32bit vs. 64bit? (Vilka adresser har ni?)

- En lösning om man råkar ut för problem

Ha en lista med rötter som hanteras explicit (`add_root`, `del_root`)

Ett vettigt första steg i implementationen ändå och användbart i testning

